Actividad 5 | Reporte técnico

ConectaSegura: predicción del abandono de clientes de telecomunicaciones

Estado: informe preparado con las ejecuciones y capturas de MLflow compartidas. La publicación en GitHub está pendiente de confirmación.

1. Objetivo y alcance

Preparar datos públicos de telecomunicaciones y comparar regresión logística y bosque aleatorio para identificar posible abandono. Este ejercicio académico aborda churn; no mide la detección de llamadas fraudulentas del proyecto original ConectaSegura.

2. Datos, fuente y supuestos

Se utilizó Telco Customer Churn de IBM: 7,043 clientes y 21 columnas, con Churn como objetivo (Yes: abandona; No: permanece). Fuente: repositorio público de IBM. Se supone que los predictores están disponibles antes de la decisión; esto requiere validación en un entorno real.

Variable / grupo	Descripción
customerID	Identificador; excluido de los predictores.
gender, SeniorCitizen, Partner, Dependents	Datos demográficos y familiares.
tenure	Meses de permanencia.
PhoneService, MultipleLines	Servicio telefónico y líneas.
InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport	Servicio de internet y complementos.
StreamingTV, StreamingMovies	Servicios de entretenimiento.
Contract, PaperlessBilling, PaymentMethod	Contrato y facturación.
MonthlyCharges, TotalCharges	Cargo mensual y cargo acumulado.
Churn	Etiqueta binaria de abandono.

3. Limpieza, estandarización y reglas

La revisión no identificó filas idénticas ni identificadores repetidos. Se quitaron espacios de texto y TotalCharges se convirtió a numérico: 11 valores vacíos o no convertibles quedaron como faltantes (0.16 %). Se conservaron los 7,043 registros y se validaron las etiquetas Yes y No. Como regla, customerID no se usa como predictor; no se eliminaron valores extremos sin justificación.

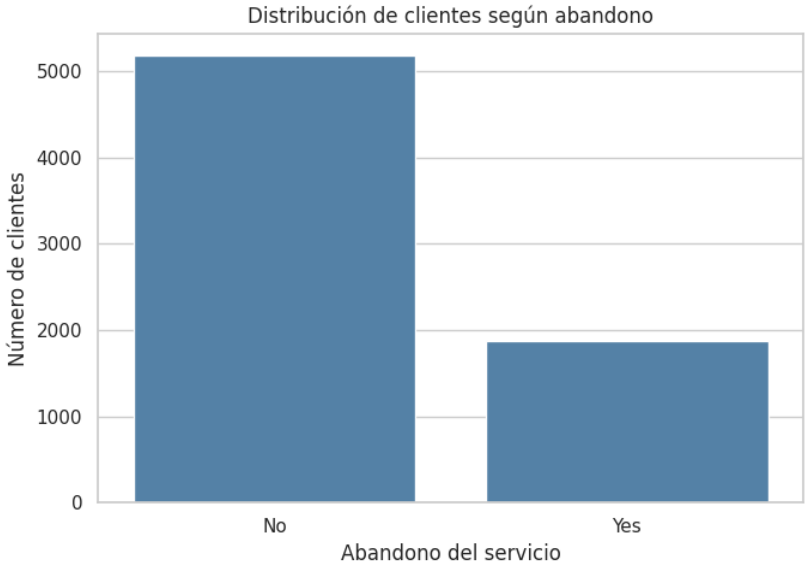
Se realizó una división estratificada 80/20 (5,634 entrenamiento; 1,409 prueba; semilla 42). Dentro de cada entrenamiento y partición de validación, el pipeline imputa la mediana numérica, escala con StandardScaler, imputa la categoría más frecuente y aplica OneHotEncoder. El tratamiento se ajusta con datos de entrenamiento para reducir fugas de información.

4. Versionamiento y reproducibilidad

Se conserva un archivo original, un CSV con limpieza básica y metadatos. La huella SHA-256 del original fue 16320c9c1ec72448db59aa0a26a0b95401046bef5d02fd3aeb906448e3055e91. Se propone versionar código, fuente, cambios y versiones de dependencias mediante Git, README y CHANGELOG. El cuaderno y MLflow registran resultados; la creación y publicación efectiva del repositorio y los scripts independientes aún requieren verificación.

5. Exploración y patrones

Permanecieron 5,174 clientes (73.46 %) y abandonaron 1,869 (26.54 %): existe desbalance. La mediana de antigüedad fue 38 meses para quienes permanecieron y 10 para quienes abandonaron; la mediana de cargos mensuales fue 64.425 y 79.650, respectivamente. Son asociaciones descriptivas, no causas.



6. Modelos y ajuste

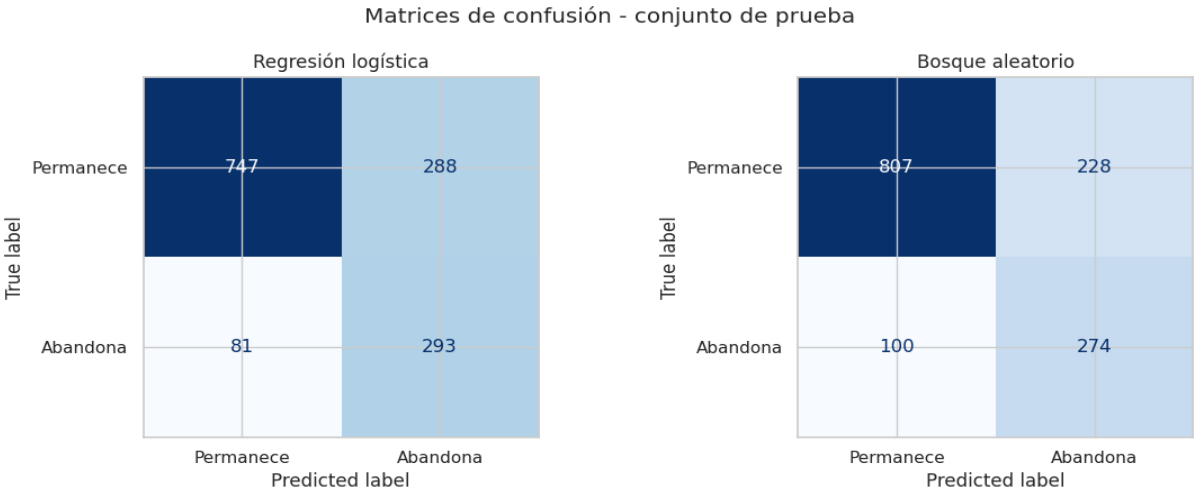
Se compararon pipelines de regresión logística y bosque aleatorio mediante GridSearchCV con validación cruzada estratificada de tres particiones sobre entrenamiento; se optimizó F1 de la clase abandono. Los pesos balanceados fueron seleccionados en ambos modelos.

Modelo	Mejores hiperparámetros	F1 CV
Regresión logística	C=1.0; class_weight=balanced	0.6291
Bosque aleatorio	n_estimators=200; max_depth=10; min_samples_leaf=3; class_weight=balanced	0.6349

7. Evaluación en prueba

Las métricas precision, recall y F1 corresponden a la clase positiva: abandono. ROC-AUC se calcula con probabilidades.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Reg. logística	0.7381	0.5043	0.7834	0.6136	0.8413
Bosque aleatorio	0.7672	0.5458	0.7326	0.6256	0.8406



La logística detectó 293 de 374 abandonos y dejó 81 sin detectar; generó 288 falsos positivos. El bosque detectó 274, dejó 100 sin detectar y produjo 228 falsos positivos. La elección depende del costo de ambas clases de error.

8. Comparación estadística

Se aplicó bootstrap pareado por percentiles (2,000 remuestreos, semilla 42), remuestreando los mismos clientes y las predicciones de ambos modelos. La diferencia observada F1 bosque menos logística fue 0.0120 y su intervalo aproximado al 95 % fue [-0.0112, 0.0346]. Como incluye cero, el análisis no permite concluir que el F1 del bosque sea superior ni demuestra equivalencia.

El intervalo refleja la variación del conjunto de prueba para modelos ya entrenados; no incluye variación por nuevo entrenamiento ni ajuste. Es exploratorio porque se consultaron los resultados de prueba; se recomienda validación independiente.

9. Registro en MLflow

El cuaderno compartido muestra MLflow 2.22.0, experimento ConectaSegura_Abandono_Clientes y una ejecución por modelo. Se registraron parámetros, métricas, resultados GridSearch, gráficas y pipelines. El bosque se recuperó y produjo predicciones [0, 1, 0, 0, 0]. Las capturas del anexo muestran ambas ejecuciones, sus métricas y los artefactos del bosque.

Ejecución	Run ID
Regresión logística	74bbed2d649e4d4abbffe05cdf3fa837
Bosque aleatorio	b73a2b79e61149fca64ef7b706c5c5ad

10. Deuda técnica y MLOps

Prioridades: fijar y verificar dependencias (incluida SQLAlchemy), separar limpieza y entrenamiento en scripts, añadir una firma de entrada, crear almacenamiento persistente y versionar datos y código. Antes de un piloto se requieren validación con datos representativos, revisión de sesgos, controles de privacidad, monitoreo de calidad y desempeño y criterios de reentrenamiento. MLflow aporta trazabilidad, pero no implementa automáticamente esos controles.

Conclusión y pendientes

El bosque aleatorio es una selección provisional según F1 de validación y menor número de falsos positivos; la logística ofrece mayor recall. La diferencia de F1 no se establece como superioridad concluyente. Pendientes: verificar el ZIP, README, CHANGELOG, datos_prep.py, train.py y publicación/verificación en GitHub. Este PDF no acredita por sí solo esos pasos.

Fuentes: IBM Telco Customer Churn (enlace de sección 2); Actividad 5 y rúbrica suministradas; cuaderno ejecutado del usuario y captura de resultado bootstrap.

Anexo. Evidencias de MLflow

Figura 1. Experimento con las ejecuciones de regresión logística y bosque aleatorio.

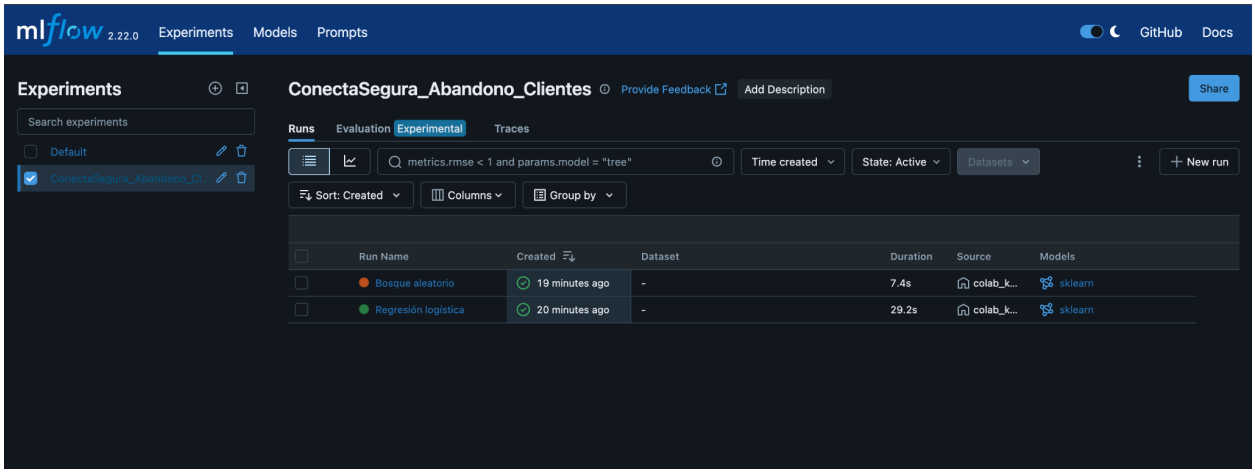
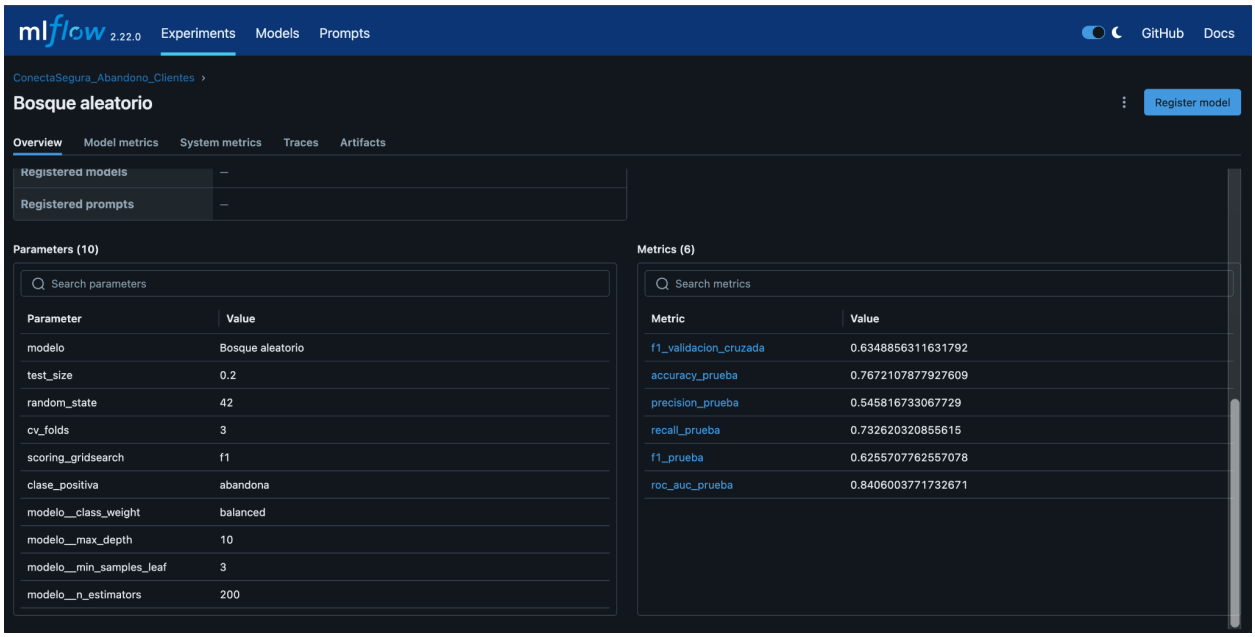


Figura 2. Parámetros y métricas de la ejecución del bosque aleatorio.



Anexo. Artefactos del bosque aleatorio

Figura 3. La carpeta modelo contiene el pipeline y archivos del entorno; también se muestran las carpetas de documentación, resultados y validación cruzada. La pantalla indica que no se registró un esquema de entrada o salida.

